

《Python 人工智能程序设计实践》中期进展报告

B07 RAG 校园智能问答助手

项目编号	B07	提交日期	2026 年 5 月 6 日
小组成员	归梦依、凌霄、周子涵、杨歆苒	当前阶段	已跑通基线模型
代码目录	当前项目目录	Demo	Streamlit + CLI

一、已完成工作

- 完成原始知识库整理与清洗：原始 32 条，清洗后 32 条，文本块 32 个。
- 覆盖 11 类校园场景：教务、考试、图书馆、一卡通、宿舍、网络、学籍、奖助、就业、活动与生活服务。
- 完成 TF-IDF 向量索引与 BM25 关键词索引，TF-IDF 词表 6638，BM25 词表 1918。
- 完成向量检索、BM25 和混合检索对比；当前选用混合检索，Hit@1=1.00，Hit@3=1.00，MRR=1.00。
- 完成命令行问答入口、Streamlit/Gradio 演示入口、评估日志和四张可视化图表。

二、数据处理细节


处理步骤	具体做法	输出文件
文档抽取	支持 PDF、DOCX、TXT、MD；真实文档放入 data/source_docs	extracted_documents.jsonl
字段校验	检查 doc_id、类别、标题、正文、来源、链接、更新时间	logs/data_profile.json
文本清洗	统一空白字符、去重、过滤过短文本，保留来源引用	knowledge_base_clean.csv
文本切分	标题与正文拼接，按约 260 字符切分；后续真实文档按约 500 字/50 字重叠切分	chunks.csv
评测集	按校园常见问题标注 gold_doc_id 和关键词，后续扩展至 50 题以上	eval_questions.jsonl

三、模型设计思路

当前系统采用“问题输入 → 多策略检索 → 证据片段组织 → 带引用回答生成”的流水线。凌霄负责的检索模块包含三种策略：TF-IDF 向量检索、BM25 关键词检索、0.5/0.5 混合检索。周子涵负责的生成模块支持通义千问/OpenAI 兼容 API；未配置 Key 时自动使用抽取式回答，保证课堂演示可复现。

四、阶段性实验结果

指标	向量检索	BM25	混合检索
Hit@1	1.00	1.00	1.00
Hit@3	1.00	1.00	1.00
MRR	1.00	1.00	1.00
平均耗时/ms	1.137	0.365	1.411



五、遇到的问题与解决方案

问题	原因分析	解决方案
无 API Key 时无法稳定调用大模型	课堂环境和网络条件不确定	保留通义千问/OpenAI 兼容接口，同时实现离线抽取式回答兜底
中文短问题检索容易受分词影响	校园问题表达短且口语化	采用字符 n-gram TF-IDF，减少分词误差
知识库规模偏小	中期阶段先跑通闭环	后续扩展到 100 条以上，并把评测问题扩展到 50 题以上

六、下一步计划

- 补充真实校园手册、学院通知和常见问答，完善数据来源记录。
- 增加向量模型对比实验：TF-IDF、BGE-small-zh、OpenAI/Qwen Embedding 或 FAISS。
- 接入通义千问 API，比较 RAG 与无检索基线回答的正确性、引用完整性和用户体验。
- 完善 Streamlit/Gradio Demo、答辩 PPT、失败案例分析和最终技术报告。