

《Python 人工智能程序设计实践》选题报告

B07 RAG 校园智能问答助手

项目编号	B07	提交日期	2026 年 5 月 6 日
项目名称	RAG 校园智能问答助手	题目来源	课程项目库 B 类
小组成员	归梦依、凌霄、周子涵、杨歆苒	组队人数	4 人
团队分工	归梦依：数据处理与知识库；凌霄：检索策略设计与优化；周子涵：大模型调用与系统开发；杨歆苒：评测分析与报告撰写	代码仓库	本地已建，可上传 GitHub/Gitee

一、项目简介

本项目拟构建面向校园办事、学习生活与公共服务场景的智能问答助手。系统不训练大模型，而是采用检索增强生成（RAG）范式：先从校园知识库中召回相关文本块，再基于证据生成带来源引用的回答，解决通用模型容易回答不准、无法说明依据的问题，并形成 RAG 系统与无检索基线、不同检索策略之间的对比实验。

二、数据来源与合规性

现阶段已整理模拟校园 FAQ 与办事指南 32 条，覆盖 11 类场景；数据字段包括编号、类别、标题、正文、来源、链接和更新时间。后续由归梦依补充学校官网学生手册、教务规定、图书馆与宿舍办事指南等 PDF/Word 原始资料；当前数据均为课程演示用公开/自建文本，不含个人隐私信息。

三、技术路线

文档抽取与清洗	切分、向量化与建库	BM25/向量/混合检索	RAG 回答、评测与 Demo
---------	-----------	--------------	-----------------

基线实现采用 pdfplumber/python-docx 抽取文档、Pandas 清洗、Scikit-learn TF-IDF 建立向量索引，并实现自定义 BM25 与 0.5/0.5 混合检索。回答模块预留通义千问/OpenAI 兼容 API；无 Key 时使用离线抽取式回答保证可复现。Demo 提供 CLI、Streamlit 和 Gradio 三种入口。

四、参考代码与资料

参考 scikit-learn TfidfVectorizer、Streamlit、Gradio、OpenAI Python SDK、DashScope 兼容接口文档，以及 RAG 相关论文和开源实现；实际代码已在本项目目录中独立实现，后续上传仓库时将在 README 中保留引用说明。

五、进度计划

第 7 周	完成选题、数据源确定、项目结构搭建	选题报告
第 8-10 周	完成数据清洗、基线检索、BM25/混合检索、评测问题集	中期进展报告
第 11-14 周	扩充真实知识库到 100 条以上，引入 Embedding/FAISS 或大模型 API，完善可视化	代码仓库更新
第 15-16 周	整理技术报告、PPT 与演示 Demo，完成答辩	最终材料